

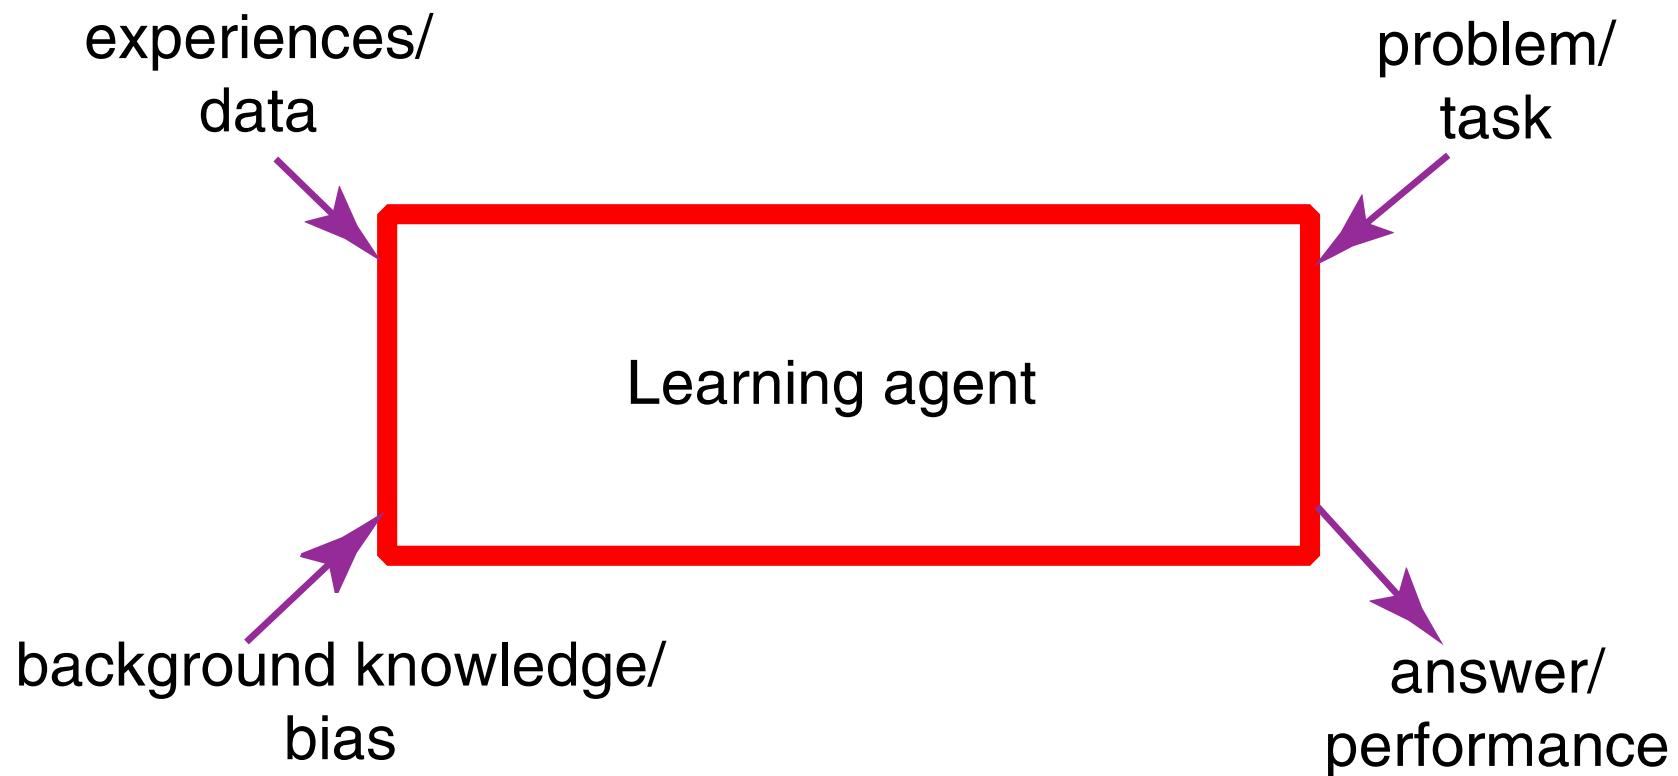
AGENTES QUE APRENDEM

Prof. Igor da Penha Natal

Aprendizagem

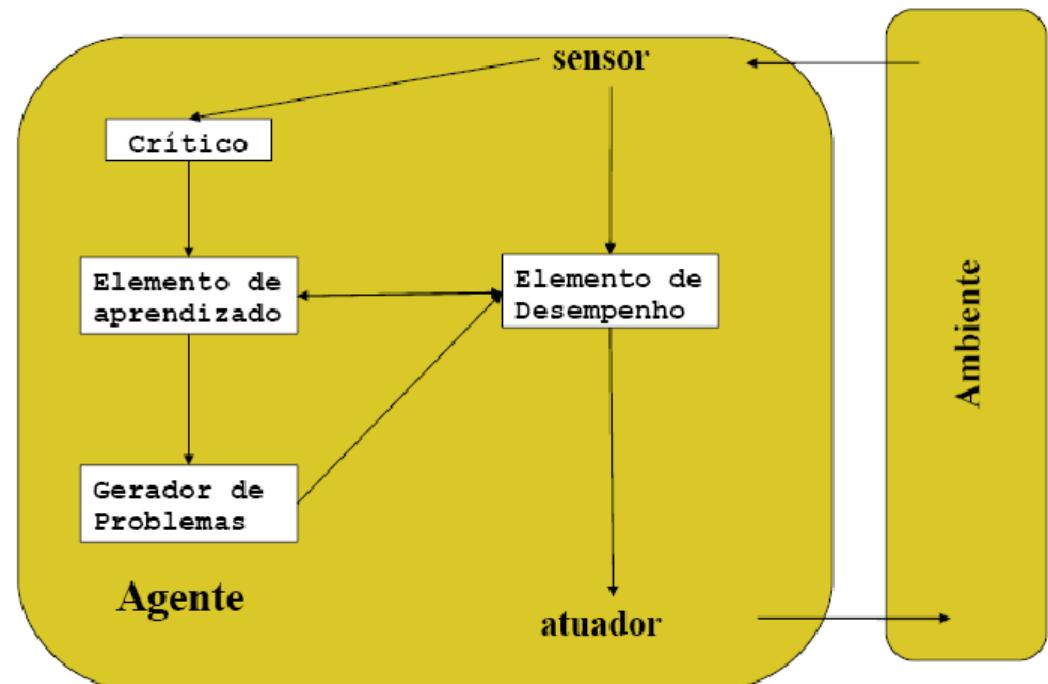
- Aprendizagem é a capacidade de melhorar seu comportamento com base na experiência.
 - ▣ A variedade de comportamentos é expandida: o agente pode fazer mais.
 - ▣ Melhora a precisão nas tarefas: o agente pode fazer as coisas melhor.
 - ▣ A velocidade é melhorada: o agente pode fazer coisas mais rapidamente.

Tarefa de aprendizagem

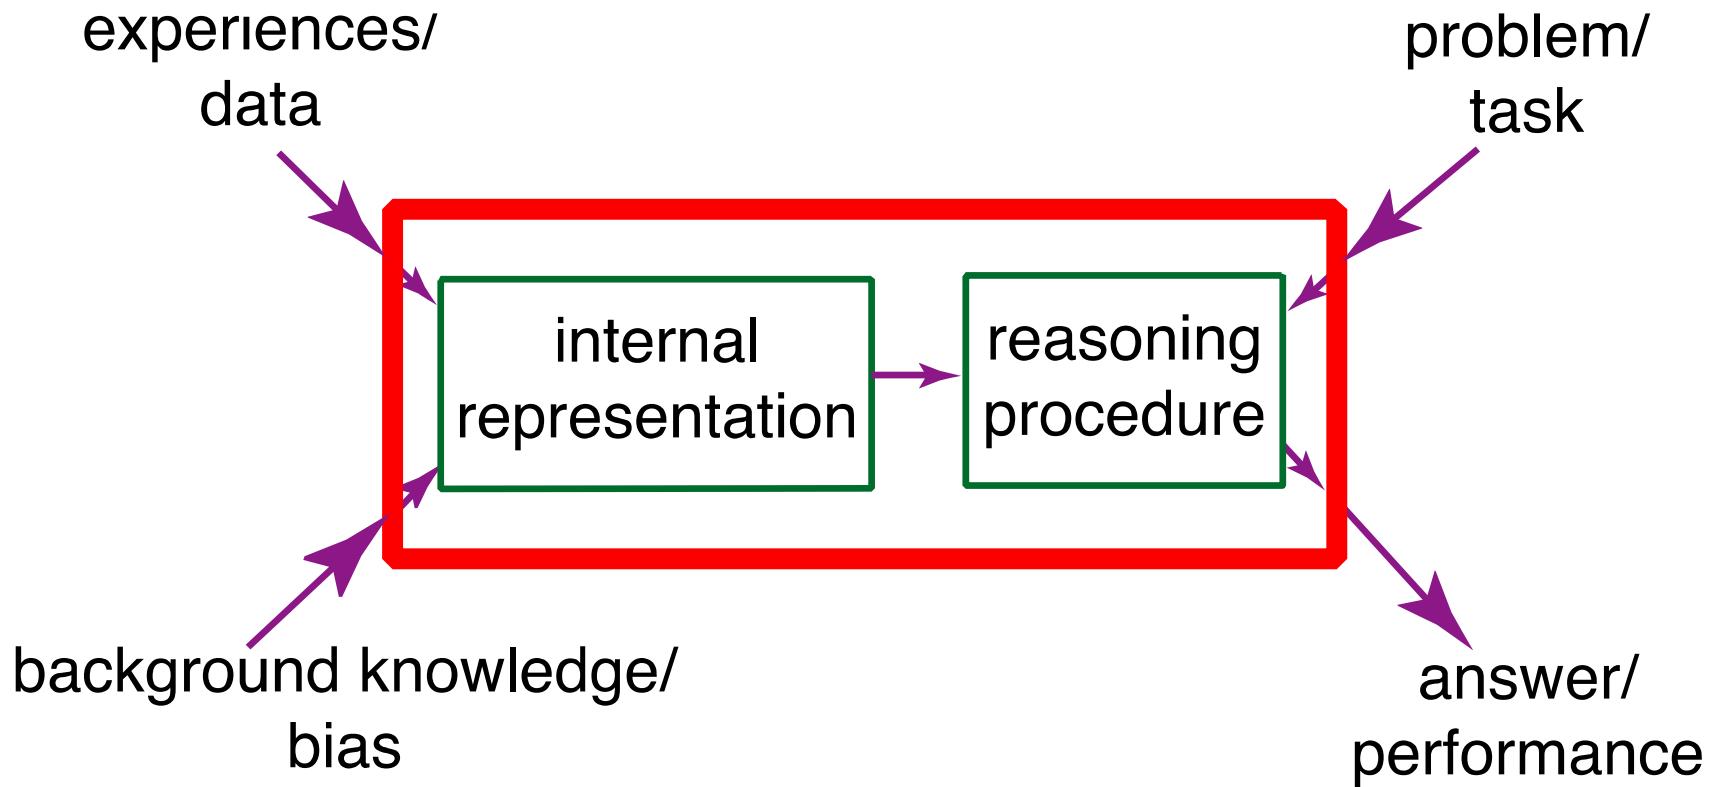


Agente de Aprendizagem

- É aquele que contém um **elemento de desempenho** que decide que ações executar e;
- Um **elemento de aprendizagem** que modifica o elemento de desempenho para que tome ações melhores.



Arquitetura de aprendizagem



Representação da Informação

- Também desempenha um papel muito importante na determinação de como o algoritmo de aprendizagem deve funcionar.
- Os componentes podem ser representados com quaisquer um dos esquemas de representação:
 - Sentenças lógicas proposicionais
 - Sentenças lógicas de primeira ordem
 - Redes Semânticas/Frames
 - Regras de produção
 - Descrições probabilísticas (redes bayesianas)
 - ...

Escolhendo uma representação

- Quanto mais rica a representação, mais útil é para resolução de problemas posteriores.
- Quanto mais rica a representação, mais difícil é para aprender.

Conhecimento Anterior

- Quando melhor o conhecimento prévio do domínio, melhor o funcionamento do algoritmo indutor.
- Inclui informações a respeito dos valores válidos de atributos, critérios de preferência na escolha de atributos, etc.

Aprendizagem Indutiva

- O objetivo de um **INDUTOR** (aprendiz) é extrair um bom classificador a partir de um conjunto de exemplos rotulados.
- A **saída do indutor** pode ser usada para classificar exemplos novos.
- Um **EXEMPLO** pode ser chamado também de **caso, registro** ou **dado** e é uma **tupla de valores de atributos** que descreve o objeto de interesse.
- Um **ATRIBUTO** é uma propriedade, ou aspecto, de um exemplo.

Aprendizagem Indutiva

- **CLASSE** é um atributo especial que descreve o fenômeno de interesse. Também denominado **rótulo**. Podem ser **discretas** ou **contínuas**.
- **Classificador** ou **HIPÓTESE** é uma estrutura que permite predizer com a maior precisão possível um novo exemplo de objeto.

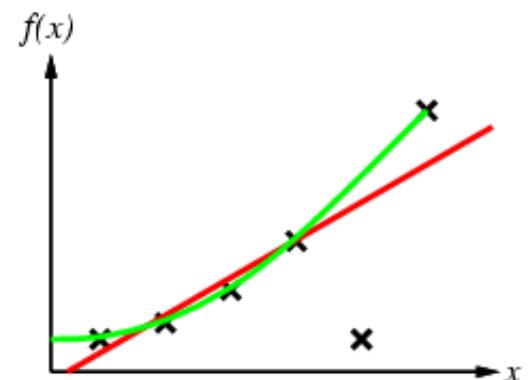
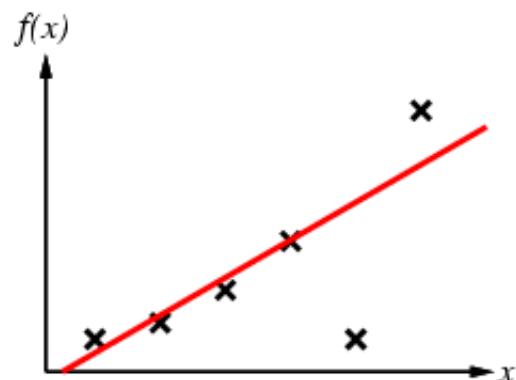
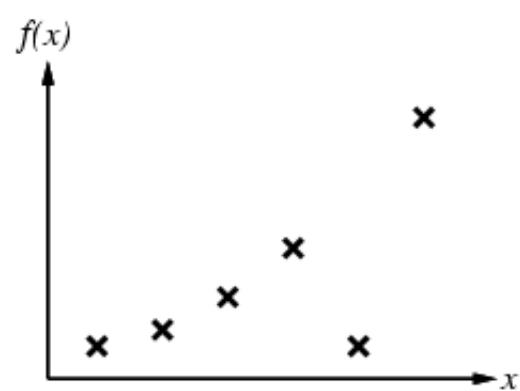
Aprendizagem Indutiva

- Recebe como entrada o valor correto de uma função desconhecida para entradas específicas e tenta recuperar a função original.
- Dada uma coleção de exemplos de f , retornar uma função h que se aproxime de f .
 - f é a função alvo.
 - h é a hipótese.
 - $(x, f(x))$ são exemplos de entrada.

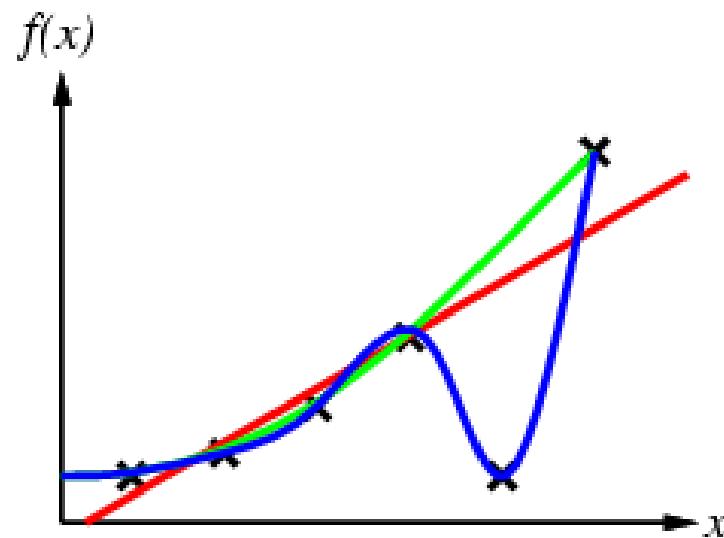
Aprendizagem Indutiva

- É o ato de construir/ajustar h de forma que ela concorde com f no conjunto de treinamento.
- h é **CONSISTENTE** se concorda com todos os exemplos dados.
- Uma boa h irá **generalizar** bem – prever corretamente exemplos ainda não vistos.

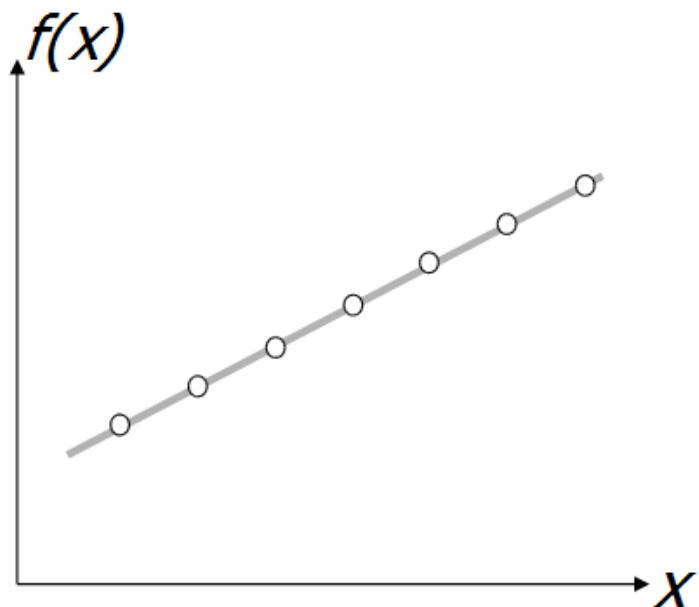
Aprendizagem Indutiva



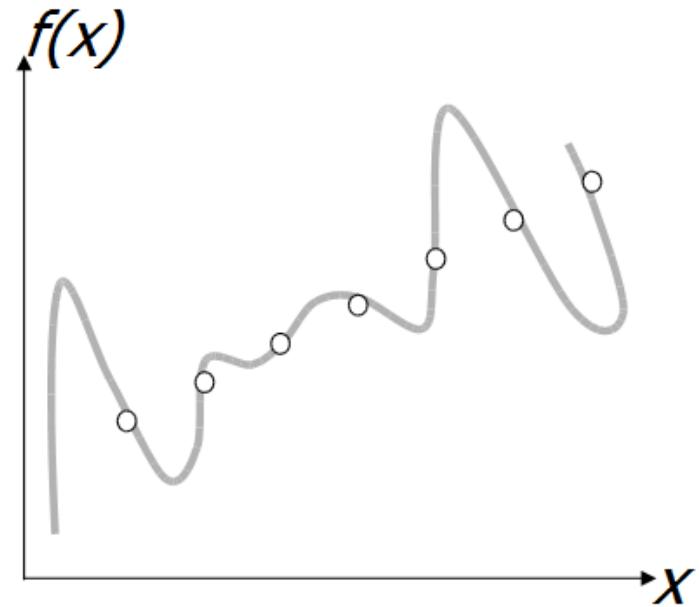
Aprendizagem Indutiva



Aprendizagem Indutiva



Uma hipótese linear
consistente



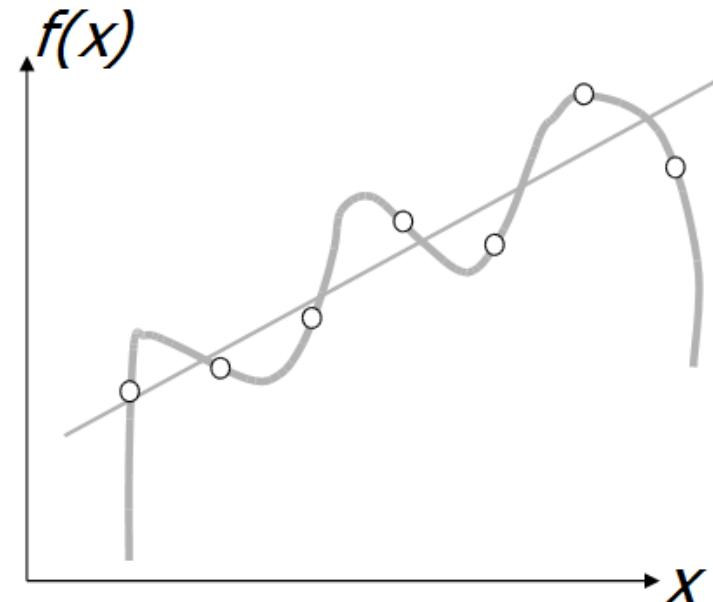
Uma hipótese de polinômio de
grau 7 consistente

Lâmina de Ockham

- Como escolher a melhor hipótese de indução dentre as diversas disponíveis?
- Prefira a **HIPÓTESE MAIS SIMPLES** consistente com os dados.
- Hipóteses que são mais complexas que os dados estão deixando de extrair algum padrão dos dados!

Aprendizagem Indutiva

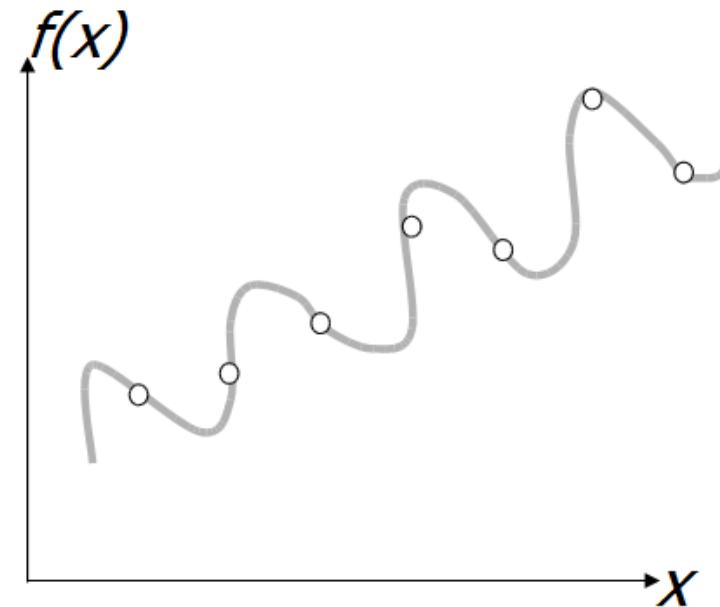
- As vezes é melhor ajustar uma simples linha reta que não seja exatamente consistente, mas possa fazer previsões razoáveis.



Um ajuste de polinômio de grau 6 exato ou um ajuste linear aproximado

Aprendizagem Indutiva

- Deve-se ter em mente que a **possibilidade** ou **impossibilidade** de encontrar uma hipótese simples e consistente depende do **ESPAÇO DE HIPÓTESE ESCOLHIDO.**
- $ax + b + c \sin x$



Um ajuste senoidal exato para o mesmo conjunto de dados

Problema de aprendizagem realizável

- Um problema de aprendizagem é **REALIZÁVEL** se o espaço de hipótese contém a função verdadeira.
 - Isto nem sempre é possível de decidir, pois a função verdadeira não é conhecida.
- É importante utilizar **conhecimento anterior** para derivar um espaço de hipóteses em que sabemos que a função verdadeira existe.

Problema de aprendizagem realizável

- Utilizar o maior espaço de hipóteses possível:
 - Por que não $H = \text{classe}$ de todas as máquinas de Turing? (já que toda função computável pode ser representada por uma máquina de Turing)
 - Ajuste de retas é fácil, ajustar polinômios de graus elevados é mais difícil e ajustar máquinas de Turing à realidade é muito difícil!
- Por isso, a maior parte do trabalho em aprendizagem se concentra em representações simples!

Feedback

- Tarefas de aprendizagem pode ser caracterizadas pelo feedback dado para o aprendiz.
 - **Aprendizado supervisionado** → o que tem de ser aprendido é especificado para cada exemplo.
 - **Aprendizado não supervisionado** → nenhuma classificação é dada; o aprendiz tem de descobrir categorias e regularidades nos dados.
 - **Aprendizagem por reforço** → o feedback ocorre após uma sequência de ações.

Tarefas comuns de aprendizagem

- **Classificação supervisionada** → dado um conjunto de exemplos de treinamento pré-classificados, classificar uma nova instância.
- **Aprendizado não supervisionado** → encontrar classes naturais para exemplos.
- **Aprendizagem por reforço** → determinar o que fazer com base em recompensas e punições.
- **Aprendizagem analítica** → raciocinar mais rápido usando a experiência da aprendizagem.
- **Programação lógica indutiva** → construir modelos mais ricos em termos de programas de lógica.

Exemplo: Aprendizagem Supervisionada

1. Agente aprende a regra condição-ação:
 - ❑ Função de estados para uma saída booleana (frear ou não).
 - ❑ O valor correto da saída é dado por um instrutor.
2. Agente aprende a reconhecer um ônibus:
 - ❑ Função a partir de imagens para uma saída booleana (a imagem contém ou não o ônibus).
 - ❑ O valor correto da saída é dado por um instrutor.
3. Agente aprende a teoria de frear:
 - ❑ Função de estados e ações para, por exemplo, a distância de parada.
 - ❑ A saída está disponível diretamente a partir das percepções do agente.

Exemplo: Aprendizagem Não Supervisionada

- O indutor analisa os exemplos fornecidos e tenta determinar se alguns deles podem ser agrupados de alguma maneira, formando **agrupamento** ou **clusters**.
- Em geral, após o agrupamento é necessário uma análise para determinar o que cada agrupamento significa no contexto do problema.
- **Exemplo:** Quais são as propriedades principais dos clientes? (segmentação do mercado)

Exemplo: Aprendizagem por Reforço

- Costuma incluir o subproblema de aprender como o ambiente funciona.
- Obtém um *feedback* na forma de quanto bem estamos fazendo (e não o que deveríamos estar fazendo), isto é, o sistema faz uma hipótese lhe dizemos “bom/ruim”.
- Útil para o controle de robôs.

Dados de exemplo para classificação

	Ação	Autor	Conversa	Comprimento	Onde
e1	pula	conhecido	nova	longa	em casa
e2	lê	desconhecido	nova	curta	trabalho
e3	pula	desconhecido	antiga	longa	trabalho
e4	pula	conhecido	antiga	longa	em casa
e5	lê	conhecido	nova	curta	em casa
e6	pula	conhecido	antiga	longa	trabalho

- Queremos classificar exemplos novos sobre a propriedade **Ação** baseado em exemplos **Autor**, **Conversa**, **Comprimento**, e **Onde**.

Mendindo o sucesso

- A **medida do sucesso** não descreve quão bem o agente desempenha sobre os exemplos de treinamento, mas quão bem o agente desempenha para novos exemplos.
- Considere dois agentes:
 - **P** afirma que os exemplos negativos vistos são os únicos exemplos negativos. Todas as outras instâncias são positivas.
 - **N** afirma que os exemplos positivos vistos são os únicos exemplos positivos. Todas as outras instâncias são negativas.
- Ambos os agentes classificam corretamente cada exemplo de treinamento, mas discordam sobre todos os outros exemplos.

Viés (*Bias*)

- A tendência a preferir uma hipótese sobre outra é chamada de **VIÉS (*bias*)**.
- Dizer que uma hipótese é melhor do que as hipóteses de **N** ou **P** não é algo que é obtido a partir dos dados.
- Para que qualquer processo indutivo faça previsões sobre dados desconhecidos, você precisa de um viés.
- O que constitui um bom viés é uma questão empírica sobre quais vieses funcionam melhor na prática.

Aprendizagem como busca

- Dada uma representação e um viés, o problema de aprendizagem pode ser reduzido a uma busca.
- Aprendizagem é uma busca através do **espaço de possíveis representações** procurando pela representação ou representações que melhor se adequam os dados, dado o viés.
- Estes espaços de busca normalmente são excessivamente grandes para a busca sistemática. Use **descida de gradiente**.
- Um algoritmo de aprendizagem é feito de um espaço de busca, uma função de avaliação e um método de busca.

Ruído

- Dados não são perfeitos:
 - Alguns dos atributos tem atribuídos o valor errado.
 - Os atributos dados são insuficientes para prever a classificação.
 - Há exemplos com ausência de atributos.
- **Superajuste (OVERFITTING)** ocorre quando uma distinção aparece nos dados, mas não aparece nos exemplos desconhecidos. Isso ocorre por causa de correlações aleatórias no conjunto de treinamento.

Caracterizações de aprendizagem

- Encontrar a melhor representação de acordo com os dados.
- Delinear a classe de representações consistentes de acordo com os dados.
- Encontrar uma distribuição de probabilidade das representações de acordo com os dados.

Aprendizado supervisionado

Dado:

- um conjunto de **propriedades de entradas** X_1, \dots, X_n .
- um conjunto de **propriedades de destino** Y_1, \dots, Y_k .
- um conjunto de **exemplos de treinamento**, nos quais os valores para os propriedades de entrada e as propriedades de destino são dadas para cada exemplo.
- um **exemplo novo**, no qual apenas os valores para as propriedades de entrada são dadas.

prever os valores para as propriedades de destino do novo exemplo.

Aprendizado supervisionado

Dado:

- um conjunto de **propriedades de entradas** X_1, \dots, X_n .
- um conjunto de **propriedades de destino** Y_1, \dots, Y_k .
- um conjunto de **exemplos de treinamento**, nos quais os valores para os propriedades de entrada e as propriedades de destino são dadas para cada exemplo.
- um **exemplo novo**, no qual apenas os valores para as propriedades de entrada são dadas.

prever os valores para as propriedades de destino do novo exemplo.

- **CLASSIFICAÇÃO** quando o Y_i são discretos.
- **REGRESSÃO** quando o Y_i são contínuos.

Avaliando previsões

- Suponha que F é um recurso e e é um exemplo:
 - $\text{val}(e, F)$ é o valor da característica F para o exemplo e .
 - $\text{pval}(e, F)$ é o valor previsto da característica F para o exemplo e .
 - O **erro** da previsão é uma medida de quão perto $\text{pval}(e, Y)$ está de $\text{val}(e, Y)$.
 - Existem muitas formas possíveis de erros que podem ser medidos.

Representações de dados de exemplos

- Um agente de viagens quer prever o tamanho preferido de uma viagem de férias, que pode ser de 1 a 6 dias. (Não há propriedade de entrada).

Duas representações dos mesmos dados (cada Y_i é uma **variável de indicador**):

Example	Y		Example	Y^1	Y^2	Y^3	Y^4	Y^5	Y^6
e^1	1		e^1	1	0	0	0	0	0
e^2	6		e^2	0	0	0	0	0	1
e^3	6		e^3	0	0	0	0	0	1
e^4	2		e^4	0	1	0	0	0	0
e^5	1		e^5	1	0	0	0	0	0

- O que é uma previsão?

Medidas de erro

- E é o conjunto de exemplos. T é o conjunto de propriedades de destino.
- **ERRO ABSOLUTO:**

$$\sum_{e \in E} \sum_{Y \in T} |val(e, Y) - pval(e, Y)|$$

Medidas de erro

- E é o conjunto de exemplos. T é o conjunto de propriedades de destino.

- **ERRO ABSOLUTO:**

$$\sum_{e \in E} \sum_{Y \in T} |val(e, Y) - pval(e, Y)|$$

- **ERRO DA SOMA DOS QUADRADOS**

$$\sum_{e \in E} \sum_{Y \in T} (val(e, Y) - pval(e, Y))^2$$

Medidas de erro

- E é o conjunto de exemplos. T é o conjunto de propriedades de destino.

- **ERRO ABSOLUTO:**

$$\sum_{e \in E} \sum_{Y \in T} |val(e, Y) - pval(e, Y)|$$

- **ERRO DA SOMA DOS QUADRADOS**

$$\sum_{e \in E} \sum_{Y \in T} (val(e, Y) - pval(e, Y))^2$$

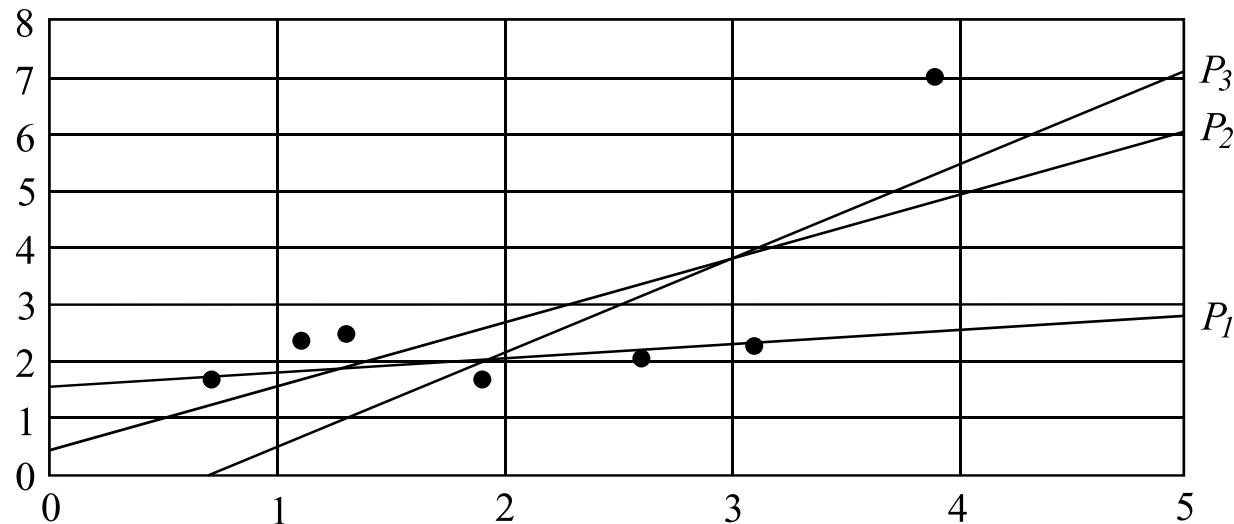
- **ERRO DO PIOR CASO**

$$\max_{e \in E} \max_{Y \in T} |val(e, Y) - pval(e, Y)| .$$

- Um erro baseado em custo

Exemplo: Previsões lineares

- P_1 minimiza o erro absoluto
- P_2 minimiza o erro da soma dos quadrados
- P_3 minimiza do erro do pior caso



Medidas de erro (cont.)

- Quando as propriedades de destino quando são {0,1}:
- **Grau de probabilidade dos dados (LIKELIHOOD):**

$$\prod_{e \in E} \prod_{Y \in T} pval(e, Y)^{val(e, Y)} (1 - pval(e, Y))^{(1 - val(e, Y))}$$

o modelo com o maior grau de probabilidade é o modelo com maior grau de probabilidade máxima (**maximum likelihood**)

Medidas de erro (cont.)

- Quando as propriedades de destino quando são {0,1}:
- **Grau de probabilidade dos dados (LIKELIHOOD):**

$$\prod_{e \in E} \prod_{Y \in T} pval(e, Y)^{val(e, Y)} (1 - pval(e, Y))^{(1 - val(e, Y))}$$

o modelo com o maior grau de probabilidade é o modelo com grau de probabilidade máxima (**maximum likelihood model**)

- **Entropia:**

$$-\sum_{e \in E} \sum_{Y \in T} [val(e, Y) \log pval(e, Y) + (1 - val(e, Y)) \log(1 - pval(e, Y))]$$

Tipo de erros na predição

- Um erro **FALSO POSITIVO**, é uma predição positiva que está errada.
- Um erro **FALSO NEGATIVO**, é uma predição falsa que está errada.
- É possível separar as questões sobre o agente ter um bom algoritmo de aprendizagem dele fazer uma boa predição baseado nas preferencias que estão for a do agente.

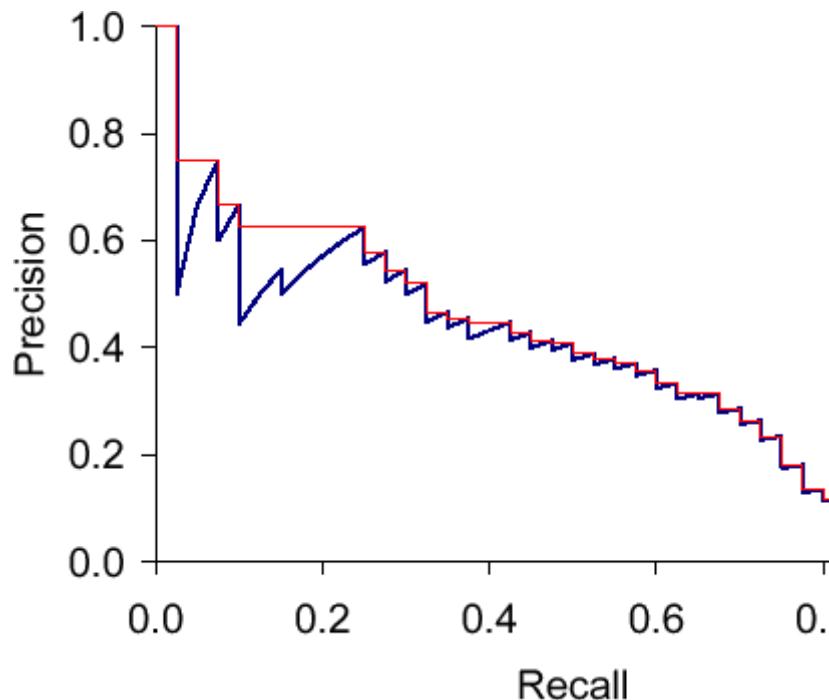
Tipo de erros na predição (sistemas binários)

Observação/Predição	Positivo verdadeiro	Negativo verdadeiro
Predição positiva	Positivo Verdadeiro (tp)	Falso positivo (fp)
Predição negativa	Falso negativo (fn)	Negativo verdadeiro (tn)

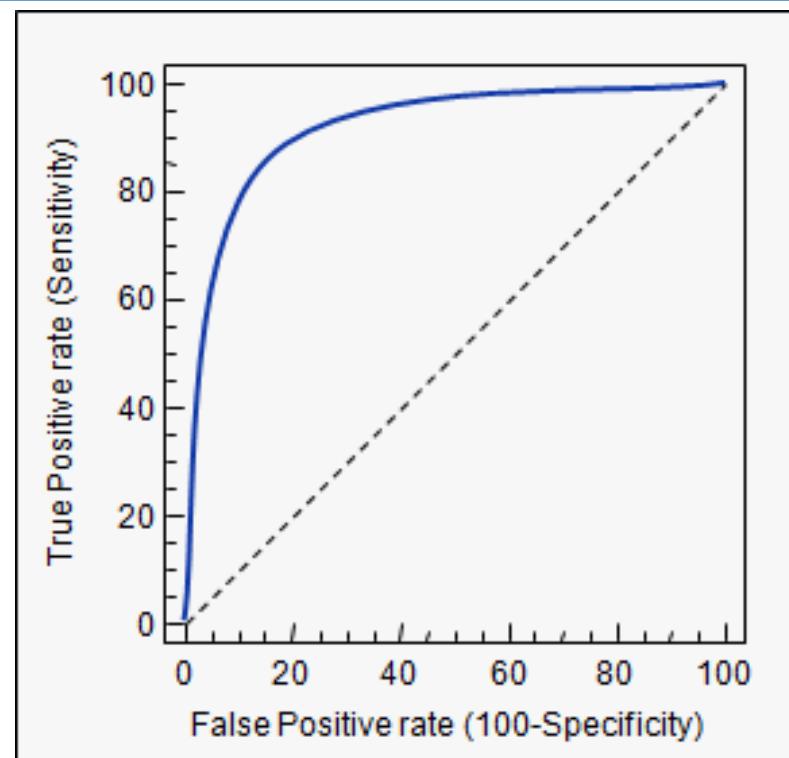
- **PRECISÃO** = $tp / (tp + fp)$
- **RECUPERAÇÃO** = $tp / (tn + fn) \rightarrow$ taxa de positivos verdadeiros
- Taxa de **ERRO FALSO POSITIVO** = $fp / (fp + tn)$

Curvas para análise de qualidade

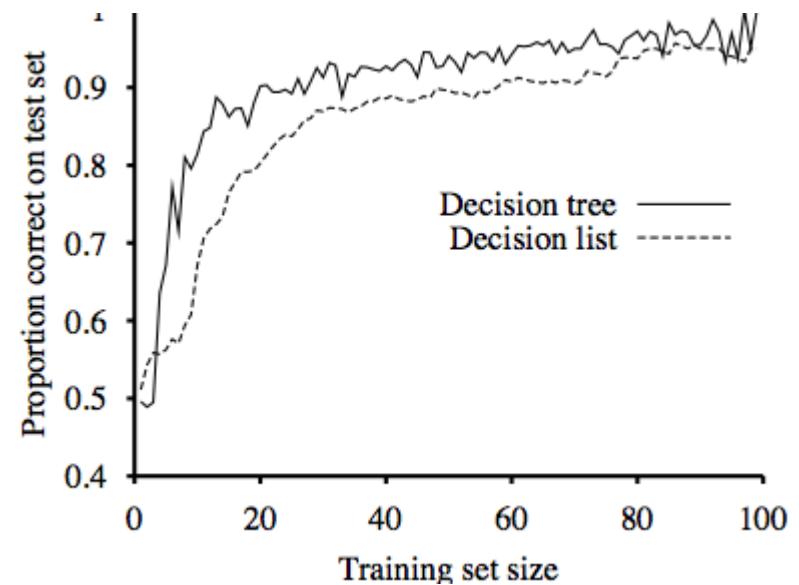
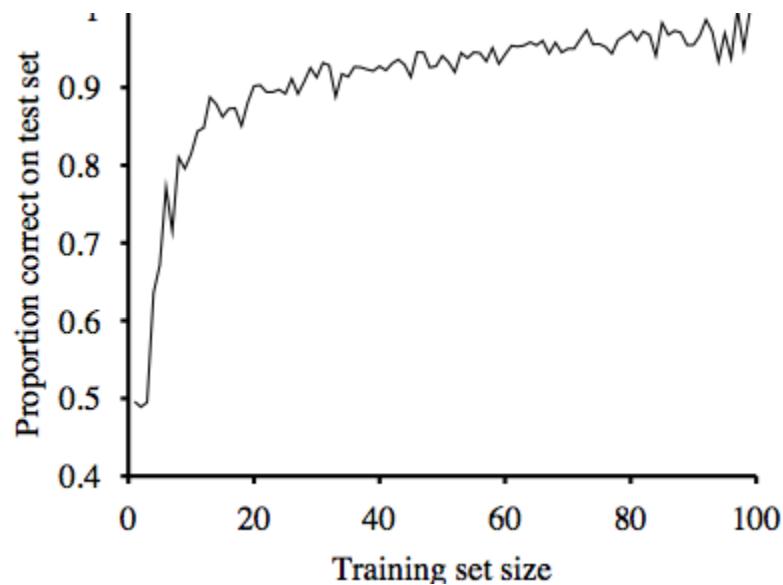
Precisão X Recuperação



Curva R.O.C.



Curvas para análise de qualidade



Estimativas de ponto

- Suponha que exista um único recurso numérico, Y . Deixe E ser os exemplos de treinamento. Há uma previsão única para todos os exemplos.
 - A previsão que minimiza a soma de **erro quadrados** em E é a **média** de Y .

Estimativas de ponto

- Suponha que exista um único recurso numérico, Y . Deixe E ser os exemplos de treinamento. Há uma previsão única para todos os exemplos.
 - A previsão que minimiza a soma de **erro quadrados** em E é a **média** de Y .
 - A previsão de que minimiza o **erro absoluto** é a **mediana** de Y .

Estimativas de ponto

- Suponha que exista um único recurso numérico, Y . Deixe E ser os exemplos de treinamento. Há uma previsão única para todos os exemplos.
 - A previsão que minimiza a soma de **erro quadrados** em E é a **média** de Y .
 - A previsão de que minimiza o **erro absoluto** é a **mediana** de Y .
 - A previsão de que minimiza o **erro do pior caso** é $(\text{máximo} + \text{mínimo})/2$.

Estimativas de ponto

- Suponha que exista um único recurso numérico, \mathbf{Y} . Deixe E ser os exemplos de treinamento. Há uma previsão única para todos os exemplos.
 - A previsão que minimiza a soma de **erro quadrados** em E é a **média** de \mathbf{Y} .
 - A previsão de que minimiza o **erro absoluto** é a **mediana** de \mathbf{Y} .
 - A previsão de que minimiza o **erro do pior caso** é $(\text{máximo} + \text{mínimo})/2$.
 - Quando \mathbf{Y} tem domínio $\{0, 1\}$, a previsão que maximiza o **grau de probabilidade** é a **probabilidade empírica**.

Estimativas de ponto

- Suponha que exista um único recurso numérico, \mathbf{Y} . Deixe E ser os exemplos de treinamento. Há uma previsão única para todos os exemplos.
 - A previsão que minimiza a soma de **erro quadrados** em E é a **média** de \mathbf{Y} .
 - A previsão de que minimiza o **erro absoluto** é a **mediana** de \mathbf{Y} .
 - A previsão de que minimiza o **erro do pior caso** é $(\text{máximo} + \text{mínimo})/2$.
 - Quando \mathbf{Y} tem domínio $\{0, 1\}$, a previsão que maximiza o **grau de probabilidade** é a **probabilidade empírica**.
 - Quando \mathbf{Y} tem domínio $\{0, 1\}$, a previsão que minimiza a **entropia** é a **probabilidade empírica**.

Estimativas de ponto

- Suponha que exista um único recurso numérico, \mathbf{Y} . Deixe E ser os exemplos de treinamento. Há uma previsão única para todos os exemplos.
 - A previsão que minimiza a soma de **erro quadrados** em E é a **média** de \mathbf{Y} .
 - A previsão de que minimiza o **erro absoluto** é a **mediana** de \mathbf{Y} .
 - A previsão de que minimiza o **erro do pior caso** é $(\text{máximo} + \text{mínimo})/2$.
 - Quando \mathbf{Y} tem domínio $\{0, 1\}$, a previsão que maximiza o **grau de probabilidade** é a **probabilidade empírica**.
 - Quando \mathbf{Y} tem domínio $\{0, 1\}$, a previsão que minimiza a **entropia** é a **probabilidade empírica**.
- Mas isso não significa que essas previsões minimizam o erro para previsões futuras.

Previsão ótima para classificação binária

- Seja n_0 número de exemplo 0 e n_1 número de exemplo 1, sem propriedades de entrada.

Prediction measure	Measure of prediction p for the training data	Optimal prediction for training data
absolute error	$n_0p + n_1(1 - p)$	$\text{median}(n_0, n_1)$
sum squares	$n_0p^2 + n_1(1 - p)^2$	$\frac{n_1}{n_0+n_1}$
worst case	$\begin{cases} p & \text{if } n_1 = 0 \\ 1 - p & \text{if } n_0 = 0 \\ \max(p, 1 - p) & \text{otherwise} \end{cases}$	$\begin{cases} 0 & \text{if } n_1 = 0 \\ 1 & \text{if } n_0 = 0 \\ 0.5 & \text{otherwise} \end{cases}$
likelihood	$p^{n_1}(1 - p)^{n_0}$	$\frac{n_1}{n_0+n_1}$
entropy	$-n_1 \log p - n_0 \log(1 - p)$	$\frac{n_1}{n_0+n_1}$

Conjuntos de Treinamento e de Teste

Para avaliar o quanto bem um aprendiz funcionará em previsões futuras, podemos dividir os exemplos em:

- **Exemplos de treinamento** que são usados para treinar o aprendiz.
- **Exemplos de teste** que são usados para avaliar o aprendiz

... os quais deve ser mantidos separados.

Aprendendo Probabilidades

- Probabilidades empíricas não criam bons previsores quando avaliadas pelo grau de probabilidade (*likelihood*) ou entropia.
- Por que?

Aprendendo Probabilidades

- Probabilidades empíricas não criam bons previsores quando avaliadas pelo grau de probabilidade (*likelihood*) ou entropia.
- Por que? Uma probabilidade de **zero** significa algo "impossível" e tem custo infinito se há um verdadeiro caso no conjunto de teste.

Aprendendo Probabilidades

- Probabilidades empíricas não criam bons previsores quando avaliadas pelo grau de probabilidade (*likelihood*) ou entropia.
- Por que? Uma probabilidade de **zero** significa algo "impossível" e tem custo infinito se há um verdadeiro caso no conjunto de teste.
- **Solução:** Adicione **PSEUDO-CONTADORES** (não-negativos) para os dados. Suponha que n_i é o número de exemplos com $X = v_i$, e c_i é o pseudo-contador:

$$P(X = v_i) = \frac{c_i + n_i}{\sum_{i'} c_{i'} + n_{i'}}$$

- Pseudo-contadores transmitem o conhecimento prévio.
 - ▣ Considere: "quanto mais eu acreditaria no valor v_i se eu tivesse visto um exemplo com v_i verdadeiro do que se eu não tivesse visto exemplos algum com v_i verdadeiro?"